

Q1

因为特征排列顺序并无特殊限制，不妨取 x_p 为因变量，其它特征为自变量，建立多元线性回归模型

$$\mathbf{x}_p = \alpha_1 \mathbf{x}_1 + \alpha_2 \mathbf{x}_2 + \cdots + \alpha_{p-1} \mathbf{x}_{p-1} + \epsilon$$

令 $\mathbf{X}_t = (\mathbf{x}_1, \mathbf{x}_2, \cdots, \mathbf{x}_{p-1})$ ， \mathbf{X}_t 是该回归模型的构造矩阵

$$\Rightarrow \hat{\mathbf{x}}_p = \mathbf{X}_t \hat{\boldsymbol{\beta}}_t = \mathbf{X}_t (\mathbf{X}_t' \mathbf{X}_t)^{-1} \mathbf{X}_t' \mathbf{x}_p$$

记 $\mathbf{H} = \mathbf{X}_t (\mathbf{X}_t' \mathbf{X}_t)^{-1} \mathbf{X}_t'$ ， \mathbf{H} 是一个帽子矩阵

$$\text{回归系数 } R_p^2 = \frac{SS_{Rp}}{SS_{Tp}}$$

其中

$$SS_{Rp} = \sum_{i=1}^n (\hat{x}_{ip} - \bar{x}_p)^2 = \sum_{i=1}^n \hat{x}_{ip}^2 = \hat{\mathbf{x}}_p' \hat{\mathbf{x}}_p = (\mathbf{H} \mathbf{x}_p)' (\mathbf{H} \mathbf{x}_p) = \mathbf{x}_p' \mathbf{H}' \mathbf{H} \mathbf{x}_p = \mathbf{x}_p' \mathbf{H} \mathbf{x}_p$$

$$SS_{Tp} = \sum_{i=1}^n (x_{ip} - \bar{x}_p)^2 = \sum_{i=1}^n x_{ip}^2 = 1$$

$$\Rightarrow R_p^2 = \mathbf{x}_p' \mathbf{H} \mathbf{x}_p$$

因为 $\mathbf{X}_s = (\mathbf{X}_t, \mathbf{x}_p)$

$$\mathbf{X}_s' \mathbf{X}_s = \begin{pmatrix} \mathbf{X}_t' \\ \mathbf{x}_p' \end{pmatrix} \begin{pmatrix} \mathbf{X}_t & \mathbf{x}_p \end{pmatrix} = \begin{pmatrix} \mathbf{X}_t' \mathbf{X}_t & \mathbf{X}_t' \mathbf{x}_p \\ \mathbf{x}_p' \mathbf{X}_t & \mathbf{x}_p' \mathbf{x}_p \end{pmatrix}$$

记 $\mathbf{X}_t' \mathbf{X}_t = \mathbf{A}_{11}$ ， $\mathbf{X}_t' \mathbf{x}_p = \mathbf{A}_{12}$ ， $\mathbf{x}_p' \mathbf{X}_t = \mathbf{A}_{21}$ ， $\mathbf{x}_p' \mathbf{x}_p = \mathbf{A}_{22}$

$$\Rightarrow (\mathbf{X}_s' \mathbf{X}_s)^{-1} = \begin{pmatrix} \mathbf{A}_{11}^{-1} + \mathbf{A}_{11}^{-1} \mathbf{A}_{12} \mathbf{M}^{-1} \mathbf{A}_{21} \mathbf{A}_{11}^{-1} & -\mathbf{A}_{11}^{-1} \mathbf{A}_{12} \mathbf{M}^{-1} \\ -\mathbf{M}^{-1} \mathbf{A}_{21} \mathbf{A}_{11}^{-1} & \mathbf{M}^{-1} \end{pmatrix}$$

其中 $\mathbf{M} = \mathbf{A}_{22} - \mathbf{A}_{21} \mathbf{A}_{11}^{-1} \mathbf{A}_{12}$

因为我们关心的是 VIF_p ，所以只需求解 \mathbf{M}^{-1}

$$\mathbf{M} = \mathbf{A}_{22} - \mathbf{A}_{21} \mathbf{A}_{11}^{-1} \mathbf{A}_{12} = \mathbf{x}_p' \mathbf{x}_p - \mathbf{x}_p' \mathbf{X}_t (\mathbf{X}_t' \mathbf{X}_t)^{-1} \mathbf{X}_t' \mathbf{x}_p = \mathbf{x}_p' \mathbf{x}_p - \mathbf{x}_p' \mathbf{H} \mathbf{x}_p = 1 - R_p^2$$

所以 $\mathbf{M}^{-1} = (1 - R_p^2)^{-1}$

因为 VIF_p 为 $(\mathbf{X}_s' \mathbf{X}_s)^{-1}$ 的第 p 个对角线元素

$$\Rightarrow VIF_p = \mathbf{M}^{-1} = \frac{1}{1 - R_p^2}$$

因为特征顺序对模型回归结果无影响，因此将任一特征作为第 p 个特征对结果无影响。

即该结论具有一般性，可推广为

$$VIF_j = \frac{1}{1 - R_j^2}$$

Q2

由最小二乘的性质可得

$$\begin{aligned} E(\hat{\beta}) &= \beta, \quad \text{Var}(\hat{\beta}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1} \\ MSE(\hat{\beta}) &= E(\hat{\beta} - \beta)'(\hat{\beta} - \beta) \\ &= E(\hat{\beta} - E\hat{\beta} + E\hat{\beta} - \beta)'(\hat{\beta} - E\hat{\beta} + E\hat{\beta} - \beta) \\ &= E(\hat{\beta} - E\hat{\beta})'(E\hat{\beta} - \beta) \\ &= \text{tr}(\text{Cov}(\hat{\beta})) \\ &= \text{tr}(\text{Var}(\hat{\beta})) \\ &= \text{tr}(\sigma^2(\mathbf{X}'\mathbf{X})^{-1}) \\ &= \sigma^2 \text{tr}(\mathbf{X}'\mathbf{X})^{-1} \end{aligned}$$

设 $\mathbf{X}'\mathbf{X}$ 的特征值为 $\lambda_1, \lambda_2, \dots, \lambda_{p+1}$

根据矩阵的性质, 有 $(\mathbf{X}'\mathbf{X})^{-1}$ 的特征值为 $\lambda_1^{-1}, \lambda_2^{-1}, \dots, \lambda_{p+1}^{-1}$, 因此

$$\text{tr}(\mathbf{X}'\mathbf{X})^{-1} = \sum_{i=1}^{p+1} \frac{1}{\lambda_i} \Rightarrow MSE(\hat{\beta}) = \sigma^2 \sum_{i=1}^{p+1} \frac{1}{\lambda_i}$$

Q3

赤池信息量准则 AIC 定义为

$$AIC = -2 \ln(\text{模型最大似然}) + 2(\text{模型独立参数个数})$$

在线性回归模型中, 假定数据满足以下分布

$$\mathbf{y} \sim \mathcal{N}_n(\mathbf{X}\beta, \sigma^2 \mathbf{I})$$

$\mathbf{y} = (y_1, y_2, \dots, y_n)'$ 的联合密度函数为

$$f(\mathbf{y}; \beta, \sigma^2) = \frac{1}{(2\pi)^{n/2} |\sigma^2 \mathbf{I}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{y} - \mathbf{X}\beta)'(\sigma^2 \mathbf{I})^{-1}(\mathbf{y} - \mathbf{X}\beta)\right)$$

参数 (β, σ^2) 的似然函数为

$$L(\beta, \sigma^2) = (2\pi)^{-n/2} (\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2}(\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta)\right)$$

对数似然函数为

$$\ln L(\boldsymbol{\beta}, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})$$

- $\boldsymbol{\beta}$ 的最大似然估计

$$\frac{\partial \ln L(\boldsymbol{\beta}, \sigma^2)}{\partial \boldsymbol{\beta}} = \frac{\partial (\frac{1}{2\sigma^2} (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}))}{\partial \boldsymbol{\beta}} = \frac{1}{\sigma^2} (-\mathbf{X})'(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) = 0$$

$$\hat{\boldsymbol{\beta}}_{\text{ML}} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{y}$$

- σ^2 的最大似然估计

$$\frac{\partial \ln L(\boldsymbol{\beta}, \sigma^2)}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) = 0$$

$$\hat{\sigma}_{\text{ML}}^2 = \frac{1}{n} (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}_{\text{ML}})'(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}_{\text{ML}}) = \frac{1}{n} (\mathbf{y} - \hat{\mathbf{y}})'(\mathbf{y} - \hat{\mathbf{y}}) = \frac{1}{n} \mathbf{e}'\mathbf{e}$$

将参数估计代入，得到最大对数似然函数

$$\ln L(\hat{\boldsymbol{\beta}}, \hat{\sigma}^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \frac{\mathbf{e}'\mathbf{e}}{n} - \frac{n}{2\mathbf{e}'\mathbf{e}} (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})'(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})$$

因此

$$\begin{aligned} \text{AIC} &= -2 \ln L(\hat{\boldsymbol{\beta}}, \hat{\sigma}^2) + 2(p+2) \\ &= n \ln(2\pi) + n \ln \frac{\mathbf{e}'\mathbf{e}}{n} + \frac{n}{\mathbf{e}'\mathbf{e}} (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})'(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) + 2(p+2) \\ &= n \ln(2\pi) + n \ln \frac{\mathbf{e}'\mathbf{e}}{n} + \frac{n}{\mathbf{e}'\mathbf{e}} (\mathbf{y} - \hat{\mathbf{y}})'(\mathbf{y} - \hat{\mathbf{y}}) + 2(p+2) \\ &= n \ln(2\pi) + n \ln \left(\frac{SS_E}{n} \right) + n + 2(p+2) \end{aligned}$$

Q4

已知岭回归估计是最小化带有 L_2 正则项的离差平方和的解，即

$$\hat{\boldsymbol{\beta}}(k) = \arg \min_{\boldsymbol{\beta}} (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) + \lambda \boldsymbol{\beta}'\boldsymbol{\beta} \quad \dots\dots\dots (1)$$

以下通过贝叶斯统计中的最大后验估计证明上式

首先考虑线性回归模型

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$$

其中， \mathbf{y} 是中心化后的响应变量， \mathbf{X} 是标准化后的特征矩阵， $\boldsymbol{\beta}$ 是待估参数，误差项 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$

在这个模型下，给定参数 $\boldsymbol{\beta}$ ，响应变量 \mathbf{y} 的似然函数为

$$\begin{aligned}
P(\mathbf{y}|\boldsymbol{\beta}) &= \frac{1}{(2\pi)^{n/2}|\sigma^2\mathbf{I}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{y}-\mathbf{X}\boldsymbol{\beta})'(\sigma^2\mathbf{I})^{-1}(\mathbf{y}-\mathbf{X}\boldsymbol{\beta})\right) \\
&= (2\pi)^{-n/2}(\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2}(\mathbf{y}-\mathbf{X}\boldsymbol{\beta})'(\mathbf{y}-\mathbf{X}\boldsymbol{\beta})\right)
\end{aligned}$$

对于 β_i , 我们选择正态分布作为其先验分布

$$\beta_i \sim \mathcal{N}(0, \tau^2), \quad i = 1, \dots, p$$

即 $\boldsymbol{\beta} \sim \mathcal{N}(\mathbf{0}, \tau^2\mathbf{I})$, 所以有

$$P(\boldsymbol{\beta}) = (2\pi)^{-p/2}(\tau^2)^{-p/2} \exp\left(-\frac{1}{2\tau^2}\boldsymbol{\beta}'\boldsymbol{\beta}\right)$$

根据贝叶斯定理, 后验分布为

$$\begin{aligned}
P(\boldsymbol{\beta}|\mathbf{y}) &= P(\mathbf{y}|\boldsymbol{\beta}) \cdot P(\boldsymbol{\beta}) \\
&= (2\pi)^{-n/2}(\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2}(\mathbf{y}-\mathbf{X}\boldsymbol{\beta})'(\mathbf{y}-\mathbf{X}\boldsymbol{\beta})\right) \cdot (2\pi)^{-p/2}(\tau^2)^{-p/2} \exp\left(-\frac{1}{2\tau^2}\boldsymbol{\beta}'\boldsymbol{\beta}\right) \\
&\propto \exp\left(-\frac{(\mathbf{y}-\mathbf{X}\boldsymbol{\beta})'(\mathbf{y}-\mathbf{X}\boldsymbol{\beta})}{2\sigma^2} - \frac{\boldsymbol{\beta}'\boldsymbol{\beta}}{2\tau^2}\right)
\end{aligned}$$

要最大化后验分布, 考虑最大化其对数函数

$$L(\boldsymbol{\beta}) = -\frac{1}{2} \left(\frac{(\mathbf{y}-\mathbf{X}\boldsymbol{\beta})'(\mathbf{y}-\mathbf{X}\boldsymbol{\beta})}{\sigma^2} + \frac{\boldsymbol{\beta}'\boldsymbol{\beta}}{\tau^2} \right)$$

可转化为最小化 $-2L(\boldsymbol{\beta})$

$$\tilde{L}(\boldsymbol{\beta}) = -2L(\boldsymbol{\beta}) = \frac{1}{\sigma^2}(\mathbf{y}-\mathbf{X}\boldsymbol{\beta})'(\mathbf{y}-\mathbf{X}\boldsymbol{\beta}) + \frac{1}{\tau^2}\boldsymbol{\beta}'\boldsymbol{\beta}$$

令 $\frac{\sigma^2}{\tau^2} = \lambda$, 所以得到后验分布的最大值

$$\begin{aligned}
\arg \min_{\boldsymbol{\beta}} \tilde{L}(\boldsymbol{\beta}) &= \arg \min_{\boldsymbol{\beta}} \left(\frac{1}{\sigma^2}(\mathbf{y}-\mathbf{X}\boldsymbol{\beta})'(\mathbf{y}-\mathbf{X}\boldsymbol{\beta}) + \frac{1}{\tau^2}\boldsymbol{\beta}'\boldsymbol{\beta} \right) \\
&= \arg \min_{\boldsymbol{\beta}} ((\mathbf{y}-\mathbf{X}\boldsymbol{\beta})'(\mathbf{y}-\mathbf{X}\boldsymbol{\beta}) + \lambda\boldsymbol{\beta}'\boldsymbol{\beta}) \quad \dots\dots\dots (2)
\end{aligned}$$

比较 (1), (2) 两式, 形式相同, 因此从贝叶斯统计的角度, 岭回归可以看作是在进行线性回归时, 通过对模型参数施加一个正态先验分布, 从而引入了 L_2 正则化。